

Detección de Aneurismas Intracraneales Usando Aprendizaje Profundo

D.A Henao Arbeláez

16 de diciembre de 2025

Resumen

En este trabajo se entrena un modelo de aprendizaje profundo para la detección y localización de aneurismas intracraneales en imágenes médicas obtenidas mediante CTA y MRA, utilizando el conjunto de datos de la competencia de la Sociedad Radiológica de Norte Amérca en Kaggle. Se empleó una arquitectura U-Net con codificador ResNet34 preentrenado y mecanismos de atención, junto con la función de costo Tversky Loss para abordar el desbalance entre clases y priorizar la detección de lesiones. El desempeño del modelo se evaluó mediante métricas como sensibilidad, precisión, F1-score y la curva Precision–Recall. Además, se implementó una estrategia de aumento de datos para mejorar la capacidad de generalización del modelo. Los resultados indican que el aumento de datos permitió mejorar la sensibilidad del modelo, pasando de 0.6658 a 0.8138, sin afectar de manera importante su capacidad para identificar correctamente el tejido sano. Esto sugiere que el enfoque propuesto, con validaciones más extensas, pruebas en otros conjuntos de datos y ajustes adicionales, podría llegar a utilizarse en el futuro como una herramienta de apoyo para el diagnóstico clínico.

Palabras Clave: Aneurismas intracraneales; aprendizaje profundo; segmentación de imágenes médicas; U-Net; data augmentation; imágenes CTA y MRA.

1. Introducción

Un aneurisma cerebral o aneurisma intracraneal es una protuberancia o abombamiento en un vaso sanguíneo del cerebro. Se forma cuando una zona débil de la pared del vaso se dilata debido a la presión que ejerce la sangre que circula por él [1, 2].

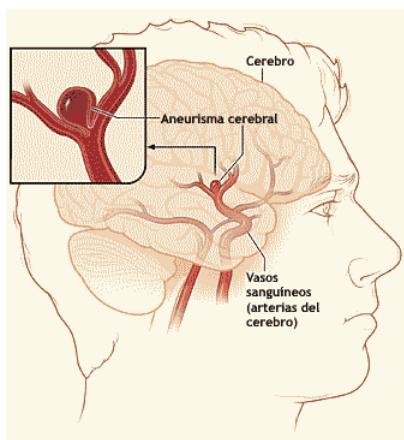


Figura 1: Diagrama de un Aneurisma Cerebral [3]

Cuando un aneurisma se rompe o presenta una

fuga, provoca sangrado en el cerebro, conocido como accidente cerebrovascular hemorrágico [1]. Este tipo de evento es una emergencia médica que puede ser mortal. Se estima que los aneurismas intracraneales afectan a alrededor del 3% de la población mundial. Sin embargo, hasta un 50% se diagnostican solo después de su rotura. A nivel mundial, estos aneurismas causan cerca de 500.000 muertes al año, y aproximadamente la mitad de las víctimas son menores de 50 años [4].

A pesar de ello, los aneurismas cerebrales son relativamente comunes, y la mayoría no son graves, especialmente si son pequeños. En muchos casos, no se rompen ni causan síntomas, y suelen descubrirse de forma incidental durante estudios de imagen realizados por otras razones médicas [1, 2].

Los radiólogos experimentados pueden detectar aneurismas en estudios de imagen cerebral, pero pueden pasar desapercibidos, sobre todo cuando las imágenes se obtienen con otros fines. Por eso, la detección automatizada, rápida y precisa de aneuris-

mas en estudios cerebrales rutinarios podría ayudar a prevenir consecuencias mortales para los pacientes [4].

En la práctica clínica se utilizan diversas técnicas de imagen para evaluar el cerebro y su vasculatura, cada una basada en principios físicos distintos y orientada a detectar tipos específicos de alteraciones. Entre las más comunes para detectar aneurismas intracraneales se encuentran la Angiotomografía Computarizada (CTA) y la Angiorresonancia Magnética (MRA) [5, 6].

La CTA es un estudio basado en tomografía computarizada que utiliza rayos X junto con la administración intravenosa de un medio de contraste yodado. Este examen está diseñado para visualizar de forma precisa las arterias y venas del cerebro, permitiendo reconstrucciones tridimensionales de la vasculatura [5].

Por otro lado, la MRA es una técnica de resonancia magnética enfocada en la visualización del árbol vascular cerebral, pero a diferencia de la CTA, no utiliza radiación y en muchas ocasiones no requiere contraste. Su principio se basa en el movimiento de la sangre dentro del campo magnético, lo cual permite resaltar los vasos sin necesidad de agentes externos [6].

La mayoría de los avances recientes en el análisis de imágenes médicas se han logrado gracias a arquitecturas profundas basadas en convolutional neural networks (CNNs), utilizadas para tareas como segmentación, clasificación y detección. Aun así, trabajar con imágenes médicas dentro del aprendizaje profundo presenta varios retos. Por un lado, las etiquetas son pocas y costosas de obtener, ya que requieren tiempo y la intervención de especialistas. Por otro lado, los datos suelen ser muy diversos y desbalanceados, ya que las condiciones de adquisición y los pacientes varían mucho, mientras que las regiones de interés suelen ocupar solo una pequeña parte de la imagen [7, 8, 9].

El uso del deep learning (DL) en este contexto se aceleró tras el éxito de las CNNs en ImageNet (2012), aunque inicialmente existían dudas sobre su aplicabilidad a imágenes clínicas debido al bajo volumen de datos etiquetados. Un avance importante ocurrió entre 2015 y 2016 con la adopción del transfer learning, que permitió reutilizar redes preentrenadas y mejorar la precisión en escenarios de datos limitados. Luego, entre 2017 y 2018, surgió la generación

de datos sintéticos como una estrategia adicional para enriquecer los conjuntos de entrenamiento [7].

También, surgieron arquitecturas diseñadas específicamente para el ámbito médico, siendo la U-Net la más influyente en segmentación biomédica gracias a su capacidad para aprender representaciones eficaces con pocos datos. Más recientemente, la investigación se ha desplazado hacia modelos más profundos (como ResNet o DenseNet), mecanismos de atención, técnicas adversariales y herramientas como el Neural Architecture Search (NAS), junto con modelos livianos que buscan mayor eficiencia computacional [7, 8].

El objetivo de este proyecto es entrenar un modelo de red neuronal U-Net capaz de **detectar** y **localizar** aneurismas intracraneales a partir de imágenes médicas del cerebro obtenidas mediante CTA y MRA.

2. Metodología

El análisis utiliza el conjunto de datos de la competencia RSNA Intracranial Aneurysm Detection de Kaggle [4].

El dataset utilizado en esta competencia reúne estudios de imágenes médicas del cerebro de 4 348 pacientes, obtenidos mediante distintas modalidades, principalmente CTA, MRA y secuencias T1 post-contraste y T2 ponderadas de MRI. Sin embargo, para el desarrollo de este proyecto se emplearon únicamente las modalidades CTA y MRA, ya que son las más adecuadas para la detección de aneurismas; de este modo, el conjunto final de trabajo quedó reducido a 3 060 pacientes. Cada serie fue anotada en trece regiones anatómicas para indicar la presencia de aneurismas, además de incluir una etiqueta binaria general que indica si existe algún aneurisma en el estudio. El archivo train.csv contiene estas etiquetas junto con información demográfica (sexo y edad) y un identificador único por serie (SeriesInstanceUID). Además, trainlocalizers.csv proporciona la localización aproximada de cada aneurisma mediante coordenadas y el identificador de la imagen específica donde aparece [4].

Las imágenes utilizadas en este proyecto provienen de un conjunto de datos que se distribuye bajo términos de uso específicos y restricciones de licencia. Por esta razón, no es posible incluir ni almacenar directamente dichas imágenes dentro del repositorio

público de GitHub ni en este informe. Únicamente se emplearon para la fase de análisis y entrenamiento del modelo en un entorno local, respetando las condiciones de acceso establecidas por los autores del dataset.

Sin embargo, sí es posible incluir en el informe y en el repositorio imágenes generadas a partir del análisis estadístico del dataset, así como visualizaciones derivadas del preprocesamiento de los datos. En particular, se incluyen ejemplos de imágenes transformadas que resultan de la combinación y modificación de cortes originales, como la construcción de imágenes de tres canales (RGB) a partir de cortes consecutivos de una misma serie. Estas imágenes no corresponden a datos clínicos crudos ni a estudios completos, sino a representaciones procesadas utilizadas con fines de análisis. Este tipo de visualizaciones no expone información clínica identificable y permite ilustrar el flujo de preprocesamiento y las características del conjunto de datos empleado.

2.1. Análisis Exploratorio de los datos

El conjunto de datos analizado está compuesto por un total de 3 060 pacientes. De ellos, 1 528 presentan aneurismas intracraneales, mientras que 1 532 corresponden a pacientes sanos. En cuanto a las variables demográficas, el conjunto de datos incluye 2 075 mujeres y 985 hombres. Respecto a las modalidades de imagen, se cuenta con 1 808 estudios de angiografía por tomografía computarizada (CTA) y 1 252 estudios de angiografía por resonancia magnética (MRA).

La Figura 2 muestra la distribución del sexo según la presencia o ausencia de aneurismas. Por su parte, la Figura 3 presenta la distribución de las edades para pacientes con y sin aneurismas.

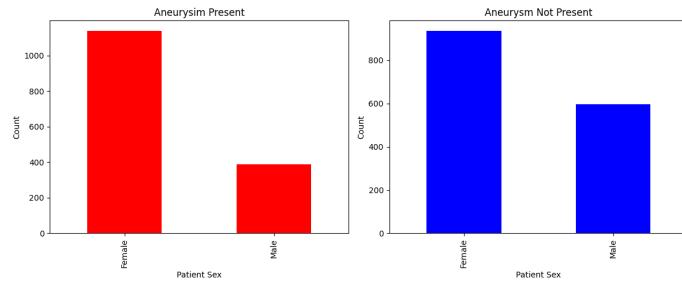


Figura 2: Distribución del sexo según presencia o ausencia de aneurisma.

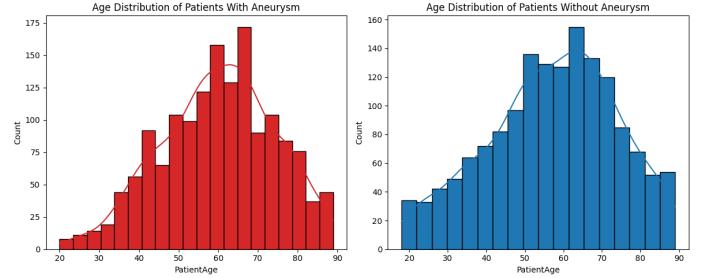


Figura 3: Distribución de edades según presencia o ausencia de aneurisma.

2.2. Extracción de Imágenes

El proceso de extracción de imágenes se implementó principalmente debido a limitaciones de memoria, ya que no se contaba con los recursos computacionales necesarios para almacenar localmente la totalidad del dataset, el cual consta de alrededor de un millón de cortes DICOM. Por esta razón, se optó por descomprimir únicamente aquellas imágenes relevantes para el análisis.

En el caso de los pacientes con aneurismas, se extrajo el corte donde se localiza la patología junto con los cortes anterior y posterior, con el objetivo de proporcionar mayor contexto espacial al modelo, dado que cada imagen corresponde a una fracción de una secuencia volumétrica y no siempre contiene la estructura cerebral completa. Estos tres cortes se combinaron en una única imagen de tres canales (RGB), como se muestra en la Figura 10. Posteriormente, los valores de intensidad de los píxeles se normalizaron al rango de 0 a 255 y se apilaron los tres cortes seleccionados para formar matrices tridimensionales, las cuales se almacenaron en formato .npy. Adicionalmente, se generó un registro que vinculaba cada archivo procesado con sus coordenadas reales y se le asignó la etiqueta positiva (1), confirmando la presencia de un aneurisma.

Para asegurar que el modelo aprendiera a diferenciar adecuadamente entre tejido sano y patológico, también se generaron muestras negativas a partir de pacientes sin aneurismas. En este caso, se seleccionaron cortes representativos de manera aleatoria, los cuales fueron sometidos al mismo proceso de normalización y conversión a formato .npy, y se les asignó la etiqueta negativa (0). Finalmente, ambos subconjuntos de datos, positivos y negativos, se juntaron en un único archivo CSV que fue utilizado para el entrenamiento del modelo de detección. Para las muestras negativas, las coordenadas de localización (x, y) se fi-

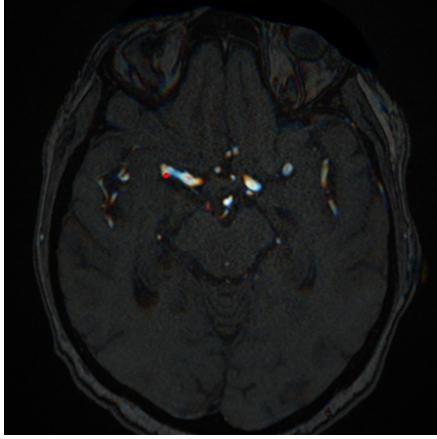


Figura 4: Imagen de tres canales construida a partir del preprocessamiento del dataset.

jaron en $(-1, -1)$ con el fin de mantener la consistencia del formato de los datos, indicando explícitamente la ausencia de un aneurisma, ya que dichos píxeles no existen en las imágenes reales. En todo momento, se trabajó con imágenes de tamaño 512×512 píxeles.

2.3. Entrenamiento del modelo

Para realizar el entrenamiento del modelo, se cargó el dataset completo y se verificó que cada imagen en formato .npy presentara las dimensiones $(512 \times 512 \times 3)$, descartando aquellas que no cumplían con estos requisitos. Posteriormente, los datos se dividieron en conjuntos de entrenamiento, validación y prueba, garantizando que todas las imágenes correspondientes a un mismo paciente permanecieran dentro del mismo subconjunto. En total, se trabajó con 2 334 pacientes, distribuidos de la siguiente manera: 2 095 imágenes correspondientes a 1 867 pacientes en el conjunto de entrenamiento, 272 imágenes de 233 pacientes en el conjunto de validación y 255 imágenes de 234 pacientes en el conjunto de prueba.

Se implementó una clase llamada `AneurysmDataset`, encargada de leer las imágenes, normalizar los valores de intensidad y generar las máscaras de segmentación asociadas. Para la construcción de estas máscaras, se dibujaron círculos blancos centrados en las coordenadas de los aneurismas, con un radio de 12 píxeles.

2.3.1. Arquitectura de la Red

La arquitectura utilizada en este trabajo se basa en el modelo U-Net, ilustrado en la Figura 5, el

cual consta de una ruta de contracción (lado izquierdo) y una ruta de expansión (lado derecho). En su formulación original, la U-Net emplea bloques convolucionales compuestos por convoluciones de 3×3 seguidas de funciones de activación ReLU y operaciones de max pooling para el submuestreo, duplicando progresivamente el número de canales de características. La ruta de expansión reconstruye la resolución espacial mediante operaciones de upsampling y convoluciones, combinando la información proveniente de la ruta de contracción a través de conexiones de salto (skip connections). Finalmente, una convolución de 1×1 permite proyectar el mapa de características al número deseado de clases [8]. Sobre esta arquitectura base, se implementó una versión adaptada para la segmentación de aneurismas intracraneales. En particular, el codificador de la U-Net original fue reemplazado por una red ResNet34 preentrenada en el conjunto de datos ImageNet, lo que permitió aprovechar características visuales previamente aprendidas y mejorar la eficiencia del entrenamiento.

Adicionalmente, se incorporó un mecanismo de atención del tipo scSE (spatial and channel Squeeze-and-Excitation) en el decodificador, el cual permite recalibrar de manera adaptativa las características espaciales y de canal, favoreciendo el enfoque del modelo en regiones relevantes de la imagen, como las zonas cercanas a los aneurismas.

Finalmente, una capa convolucional de 1×1 se utilizó para proyectar el mapa de características final a una única clase de salida, correspondiente a la segmentación binaria de aneurismas.

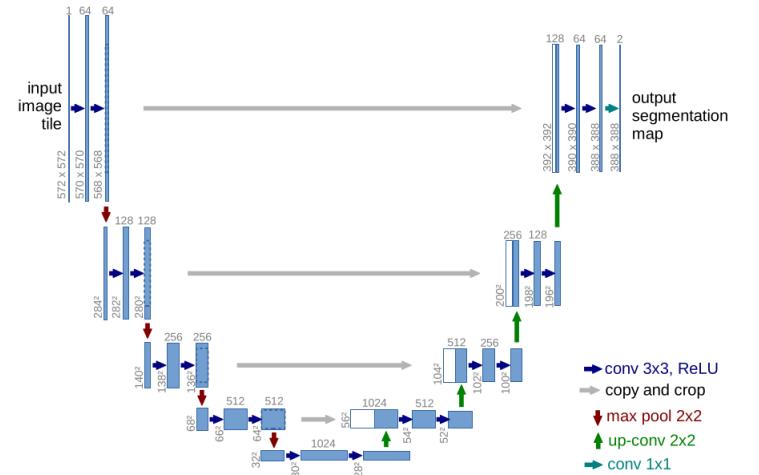


Figura 5: Arquitectura red U-Net [8].

2.3.2. Función de costo

La función de costo utilizada en este trabajo es la *Tversky Loss*, una generalización del coeficiente Dice diseñada para problemas de segmentación con clases altamente desbalanceadas. Su formulación matemática se define como una razón entre la intersección de la predicción y la referencia, y una combinación ponderada de verdaderos positivos, falsos positivos y falsos negativos. En esta expresión, p_{0i} representa la probabilidad predicha de que el vóxel i pertenezca a la clase aneurisma, mientras que p_{1i} corresponde a la probabilidad de la clase no aneurisma. De forma análoga, g_{0i} y g_{1i} indican las etiquetas reales del vóxel i [9].

Los parámetros α y β controlan la penalización asociada a los falsos positivos y falsos negativos, respectivamente. Esto permite ajustar el compromiso entre precisión y sensibilidad según las necesidades del problema. En particular, valores altos de β incrementan la penalización de los falsos negativos, favoreciendo una mayor sensibilidad del modelo [9].

$$T(\alpha, \beta) = \frac{\sum_{i=1}^N p_{0i}g_{0i}}{\sum_{i=1}^N p_{0i}g_{0i} + \alpha \sum_{i=1}^N p_{0i}g_{1i} + \beta \sum_{i=1}^N p_{1i}g_{0i}}$$

Durante el entrenamiento se utilizó un valor alto del parámetro β ($\beta = 0,9$), con el fin de favorecer la detección de aneurismas y reducir al máximo los casos en los que el modelo no los identifica. Esta configuración permite penalizar con mayor peso los falsos negativos.

2.3.3. Evaluación del Modelo

La evaluación del modelo se realizó utilizando el conjunto de prueba, calculando el Dice Score, una métrica que mide qué tanto se superponen dos regiones: la predicción del modelo y la máscara real (ground truth) [9].

$$\text{Dice} = \frac{2TP}{2TP + FP + FN}$$

También, se construyó una matriz de confusión a nivel de píxel, a partir de la cual se calcularon métricas relevantes como la sensibilidad, que mide la capacidad del modelo para detectar correctamente los píxeles asociados a aneurismas; la especificidad, que refleja qué tan bien identifica el tejido sano o fondo; y la precisión, que indica qué proporción de los píxeles clasificados como aneurisma son realmente correctos. Asimismo, se calculó el F1-score, el

cual combina sensibilidad y precisión en una única métrica balanceada. Para obtener estas métricas se aplicó un umbral de decisión de 0.3 sobre el mapa de probabilidades, priorizando la detección de aneurismas y reduciendo el riesgo de falsos negativos, un aspecto especialmente importante en un contexto clínico donde omitir una lesión puede tener consecuencias graves. Finalmente, se generó la curva Precision–Recall para evaluar el desempeño del modelo en un escenario de clases desbalanceadas.

Además, se realizaron visualizaciones cualitativas para entender mejor el comportamiento del modelo. En estas visualizaciones se comparan la imagen original, la máscara de referencia (ground truth), el mapa de probabilidades generado por la red y la predicción binaria final. Este análisis visual permitió evaluar de manera más intuitiva en qué regiones el modelo logra identificar correctamente los aneurismas y en cuáles presenta dificultades.

Los resultados obtenidos con este primer modelo se presentan en la siguiente sección. No obstante, su desempeño aún no alcanzó niveles considerados adecuados para una aplicación confiable, particularmente en el ámbito médico. Por esta razón, se decidió implementar una estrategia de data augmentation o aumento de datos, con el objetivo de mejorar la capacidad de generalización del modelo.

2.4. Data Augmentation

Para realizar el aumento de datos, se definió una secuencia de transformaciones geométricas y de color utilizando la librería albumentations. Estas transformaciones incluyeron volteos horizontales y verticales, rotaciones, escalados y ajustes de brillo, con el objetivo de incrementar la variabilidad de las imágenes de entrenamiento y mejorar la capacidad de generalización del modelo. Un aspecto clave de este proceso fue el manejo de los keypoints (coordenadas del aneurisma), asegurando que se transformaran de manera consistente junto con la imagen.

El código recorrió cada imagen original que contenía aneurismas y, para cada una, aplicó las transformaciones definidas un número controlado de veces (NGENERAR = 1). Durante este procedimiento, se verificó que el aneurisma no desapareciera de la imagen tras la transformación (por ejemplo, debido a rotaciones o recortes) y que las dimensiones finales se mantuvieran en 512×512 píxeles. Si la

imagen aumentada cumplía con estas condiciones, se guardaba en disco con un nuevo nombre y se registraba su información correspondiente, incluyendo las nuevas coordenadas calculadas. Finalmente, los datos originales se combinaron con las nuevas muestras generadas y se exportó un archivo CSV consolidado, el cual fue utilizado como entrada para el entrenamiento de la red neuronal.

El conjunto final quedó conformado por un total de 2 334 pacientes. El conjunto de entrenamiento se amplió hasta 3 271 imágenes, correspondientes a 1 867 pacientes, gracias a la incorporación de muestras generadas mediante data augmentation. Por su parte, los conjuntos de validación y prueba se mantuvieron separados del proceso de aumento de datos, quedando compuestos por 424 imágenes (233 pacientes) y 400 imágenes (234 pacientes), respectivamente.

3. Resultados y Análisis

3.1. Resultados del modelo sin el aumento de datos

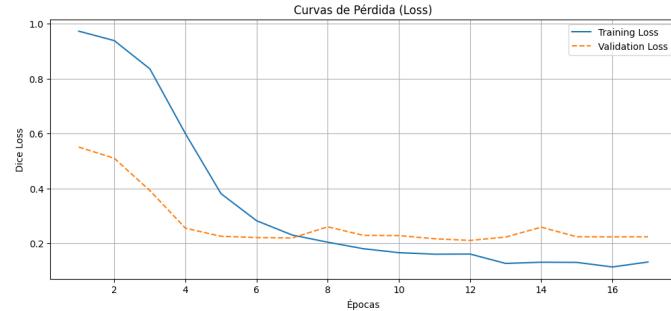


Figura 6: Función de costo de entrenamiento y validación.

El modelo alcanzó una sensibilidad de 0.6658, lo que indica que logra identificar cerca del 66.6 % de los píxeles asociados a aneurismas. Esto sugiere que, en general, el modelo es capaz de detectar una parte importante de las regiones patológicas. En contraste, la especificidad fue muy alta (0.9989), lo que muestra que el modelo distingue con gran precisión los píxeles sanos, generando muy pocos falsos positivos.

La precisión obtenida (0.3718) indica que, aunque el modelo señala varias regiones como aneurismas, una proporción considerable de estas predicciones no corresponde realmente a la patología. Finalmente, el F1-score de 0.4772 refleja el balance entre sensibilidad y precisión, evidenciando que el modelo está orientado

a priorizar la detección de aneurismas, aún a costa de introducir errores en algunas predicciones positivas.

La curva Precision–Recall, Figura 9, muestra cómo cambia el desempeño del modelo al variar el umbral de decisión, poniendo en relación la precisión (qué tan confiables son las detecciones de aneurisma) con el recall o sensibilidad (qué proporción de aneurismas reales logra detectar). En esta curva se observa que, a medida que se incrementa la sensibilidad, la precisión disminuye, lo cual refleja que para detectar más aneurismas, el modelo tiende a generar más falsos positivos. El valor de Average Precision ($AP = 0.3229$) resume el área bajo esta curva y proporciona una medida global del rendimiento del modelo, indicando que, aunque el modelo es capaz de alcanzar niveles relativamente altos de sensibilidad, lo hace a costa de una precisión moderada.

3.2. Resultados del modelo con aumento de datos

El nuevo modelo alcanzó una sensibilidad de 0.8138, lo que representa una mejora notable en la capacidad de detectar los píxeles asociados a aneurismas, logrando identificar más del 81 % de las regiones patológicas presentes en las imágenes.

La especificidad se mantuvo en un valor muy alto (0.9977), lo que indica que el modelo continúa clasificando correctamente la gran mayoría de los píxeles sanos, con una baja tasa de falsos positivos. Sin embargo, la precisión obtenida (0.3017) muestra que una parte considerable de las detecciones positivas no corresponde realmente a aneurismas.

Finalmente, el F1-score de 0.4402 refleja el equilibrio entre sensibilidad y precisión, lo que significa que el modelo está orientado a priorizar la detección de aneurismas.

En este caso, a partir de la curva Precision–Recall mostrada en la Figura 13, se observa que la precisión es, en general, mayor que en el modelo anterior, lo que sugiere que las detecciones de aneurismas realizadas por el modelo son más confiables. Esta mejora se refleja en el incremento del valor de Average Precision ($AP = 0.3860$), el cual resume el desempeño global del modelo a lo largo de distintos umbrales de decisión. Como es habitual en problemas altamente desbalanceados, la precisión disminuye a medida que aumenta el recall; sin embargo, esta caída ocurre de forma más gradual, lo que indica un mejor compromiso entre la capacidad de detectar aneurismas y el

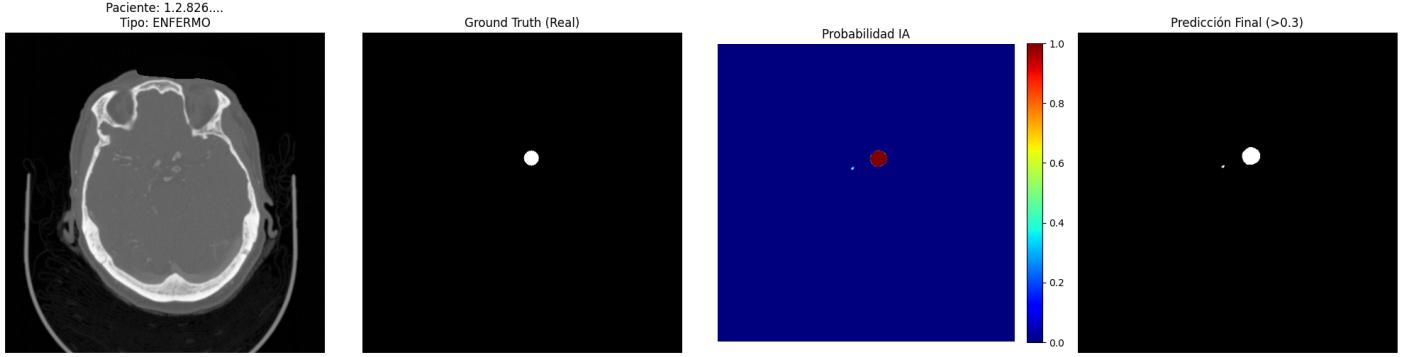


Figura 7: Visualización de las predicciones del modelo.

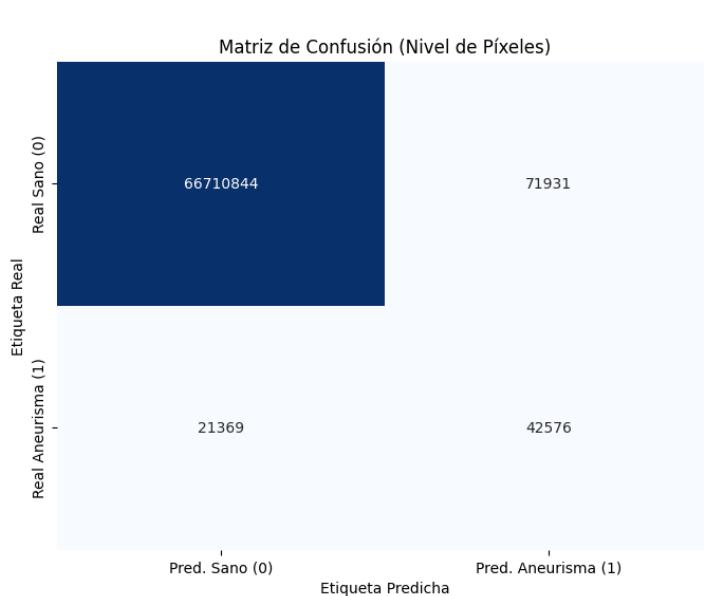


Figura 8: Matriz de confusión de los resultados del modelo.

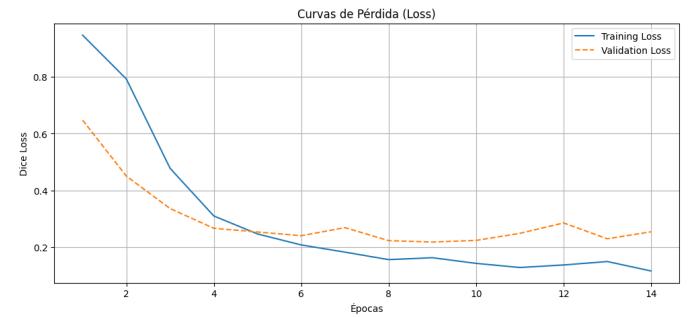


Figura 10: Función de costo de entrenamiento y validación con aumento de datos.

control de falsos positivos.

4. Conclusiones

Al comparar el desempeño del modelo entrenado sin aumento de datos con el modelo que incorpora data augmentation, se observa una mejora clara en la capacidad para detectar aneurismas. En particular, la sensibilidad aumentó de 0.6658 a 0.8138, lo que indica que el nuevo modelo logra identificar una mayor proporción de las regiones patológicas presentes en las imágenes.

Por otro lado, la especificidad se mantuvo muy alta en ambos casos, con valores de 0.9989 y 0.9977, respectivamente. Esto implica que el incremento en la sensibilidad no afectó de manera significativa la capacidad del modelo para reconocer correctamente el tejido sano. En otras palabras, el modelo mejorado detecta más aneurismas reales sin generar un aumento excesivo de falsas alarmas.

En cuanto a la precisión, se observa una disminución de 0.3718 a 0.3017, un comportamiento esperable dado que el entrenamiento se orientó a

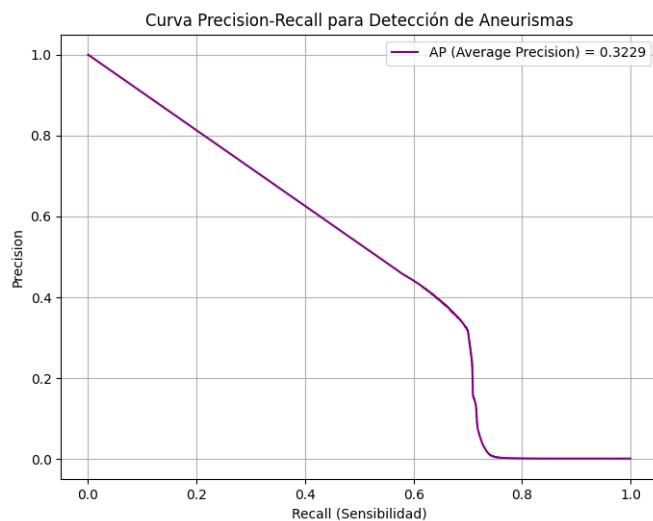


Figura 9: Curva Precision-Recall.

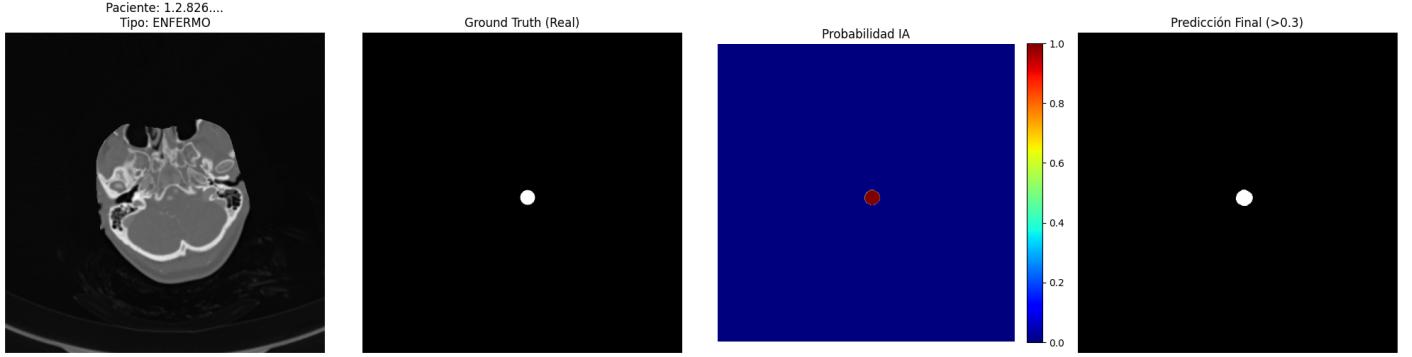


Figura 11: Visualización de las predicciones del modelo con aumento de datos.



Figura 12: Matriz de confusión de los resultados del modelo con aumento de datos.

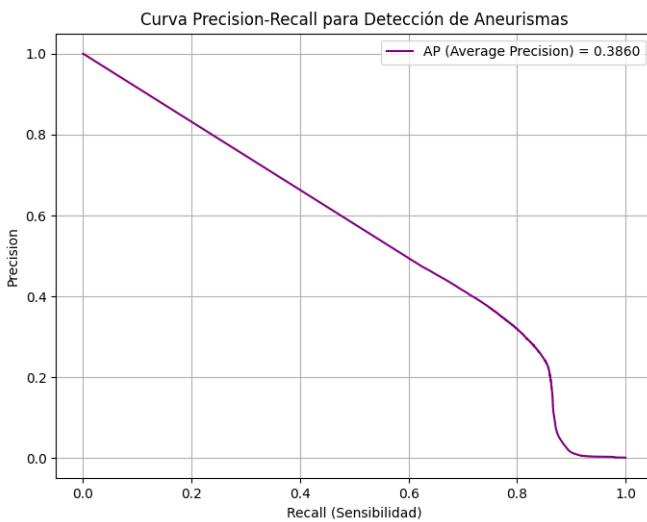


Figura 13: Curva Precision–Recall con aumento de datos.

priorizar la detección de aneurismas. En un problema tan desbalanceado como este, donde los píxeles correspondientes a la patología representan una fracción muy pequeña del total, mejorar la sensibilidad suele implicar aceptar un mayor número de predicciones positivas incorrectas.

El F1-score, que resume el equilibrio entre sensibilidad y precisión, se mantuvo en un rango similar en ambos modelos, pasando de 0.4772 a 0.4402. Este resultado indica que, aunque la precisión disminuyó un poco, el aumento en la capacidad de detección compensa este efecto, logrando un desempeño global comparable pero con un enfoque más adecuado desde el punto de vista clínico.

En conjunto, estos resultados muestran que el uso de aumento de datos permitió entrenar un modelo más sensible y mejor adaptado a la tarea de detección de aneurismas intracraneales.

Como trabajo futuro, se podrían explorar distintas estrategias para seguir mejorando el desempeño del modelo. Entre ellas, probar arquitecturas más avanzadas, combinar funciones de pérdida que equilibren mejor sensibilidad y precisión, o ajustar de manera más cuidadosa el umbral de decisión utilizando la curva Precision–Recall. Asimismo, el uso de modelos tridimensionales permitiría aprovechar mejor la información volumétrica de los estudios.

Nota sobre el uso de herramientas de inteligencia artificial

Durante el desarrollo de este trabajo se utilizaron herramientas de inteligencia artificial, específicamente ChatGPT [10] y Gemini 3 Pro [11], como apoyo en distintas etapas del proceso. Estas herramientas

fueron empleadas para la aclaración de dudas conceptuales, la generación y revisión de fragmentos de código, la propuesta de ideas metodológicas, recomendaciones bibliográficas y la mejora de la redacción y claridad del texto.

Referencias

- [1] Mayo Clinic. *Aneurisma cerebral: síntomas y causas*. Recuperado el 31 de octubre de 2025. 2025. URL: <https://www.mayoclinic.org/es/diseases-conditions/brain-aneurysm/symptoms-causes/syc-20361483>.
- [2] American Stroke Association. *Let's Talk About Brain Aneurysms*. Recuperado el 17 de octubre de 2025. 2025. URL: <https://www.stroke.org/es/help-and-support/resource-library/lets-talk-about-stroke/brain-aneurysms>.
- [3] Wikipedia. *Aneurisma cerebral*. Accedido el 4 de diciembre de 2025. 2025. URL: https://es.wikipedia.org/wiki/Aneurisma_cerebral.
- [4] Kaggle, Inc. *RSNA Intracranial Aneurysm Detection*. Competencia de Kaggle. Consultado el 17 de octubre de 2025. 2025. URL: https://www.kaggle.com/competitions/rsna-intracranial-aneurysm-detection/data?select=train_localizers.csv.
- [5] AdminAPacs. *TAC y RM: ¿en qué se diferencian estas técnicas imagenológicas?* <https://www.actualpacs.com/blog/2017/07/13/diferencias-tac-rm/>. Blog de Teleradiología — Actualidad. Abr. de 2020.
- [6] MedlinePlus. *Angiografía por resonancia magnética: Encyclopedia médica*. <https://medlineplus.gov/spanish/ency/article/007269.htm>. Recuperado el 15 de noviembre. 2024.
- [7] S. K. Zhou et al. “A review of deep learning in medical imaging: Imaging traits, technology trends, case studies with progress highlights, and future promises”. En: *Proceedings of the IEEE* 109.5 (2021), págs. 820-838. DOI: 10.1109/JPROC.2021.3054390.
- [8] Olaf Ronneberger, Philipp Fischer y Thomas Brox. *U-Net: Convolutional Networks for Biomedical Image Segmentation*. 2015. arXiv: 1505.04597 [cs.CV]. URL: <https://arxiv.org/abs/1505.04597>.
- [9] Seyed Sadegh Mohseni Salehi, Deniz Erdogmus y Ali Gholipour. *Tversky loss function for image segmentation using 3D fully convolutional deep networks*. 2017. arXiv: 1706.05721 [cs.CV]. URL: <https://arxiv.org/abs/1706.05721>.
- [10] OpenAI. *ChatGPT*. <https://chat.openai.com>. Modelo de lenguaje de gran escala utilizado como herramienta de apoyo para generación de código, aclaración conceptual y mejora de la redacción. 2024.
- [11] Google. *Gemini 3 Pro*. <https://deepmind.google/technologies/gemini/>. Modelo de lenguaje de gran escala utilizado como herramienta de apoyo para generación de ideas, recomendaciones bibliográficas y asistencia en programación. 2024.